

# Intégration - Résumé

October 25, 2023

THEVENET Louis

## Table des matières

1. Estimation .....	1
1.1. Modèle statistique, estimateurs .....	1
1.2. Vraisemblance .....	1
1.3. Inégalité de Cramér Rao .....	1
1.4. Maximum de vraisemblance .....	2
1.5. Méthode des moments (construire un estimateur) .....	2
1.6. Estimation Bayésienne .....	2
2. Tests Statistiques .....	4
3. Au partiel .....	6

## 1. Estimation

Qualités d'un estimateur

### 1.1. Modèle statistique, estimateurs

#### Définition 1.1.1 :

On note  $\hat{\theta}(X_1, \dots, X_n)$ ,  $\hat{\theta}_n$  ou  $\hat{\theta}$  l'estimateur lié aux  $n$  VA *iid*  $X_1, \dots, X_n$  elles-mêmes liées aux  $n$  observations  $x_1, \dots, x_n$

- Biais :  $b_n(\theta) = E(\hat{\theta}_n) - \theta \in \mathbb{R}^p$
- Variance :  $v_n(\theta) = E\left[(\hat{\theta}_n - E(\hat{\theta}_n))^2\right]$
- Matrice de covariance :  $E\left[(\hat{\theta}_n - E(\hat{\theta}_n))(\hat{\theta}_n - E(\hat{\theta}_n))^T\right]$
- Erreur quadratique moyenne (MSE) :  $e_n(\theta) = E\left[(\hat{\theta}_n - \theta)^2\right] = v_n(\theta) + b_n^2(\theta)$
- un estimateur  $\hat{\theta}_n$  est convergent si  $\lim_{n \rightarrow +\infty} b_n(\theta) = \lim_{n \rightarrow +\infty} v_n(\theta) = 0$

### 1.2. Vraisemblance

#### Définition 1.2.1: Vraisemblance

$$L(x_1, \dots, x_n; \theta) = \begin{cases} X_i \text{ VA discrète } P[X_1 = x_1, \dots, X_n = x_n; \theta] \\ X_i \text{ VA continue } p(x_1, \dots, x_n; \theta) \end{cases}$$

### 1.3. Inégalité de Cramér Rao

**Théorème 1.3.1:**

$$\text{Var}(\hat{\theta}_n) \geq \frac{[1 + b'_n(\theta)]^2}{(-E\left[\frac{\partial^2 \ln(L(X_1, \dots, X_n; \theta))}{\partial \theta^2}\right])} = \text{BCR}(\theta)$$

- *BCR* : Borne de Cramér-Rao
- $L(X_1, \dots, X_n; \theta)$  : vraisemblance
- **Hypothèses** :
  1. log-vraisemblance deux fois dérivable
  2. support de la loi indépendant de  $\theta$

## 1.4. Maximum de vraisemblance

**Définition 1.4.1:** Maximum de vraisemblance

$$\hat{\theta}_{\text{MV}} = \arg \max_{\theta} L(X_1, \dots, X_n; \theta)$$

**Théorème 1.4.1:** Recherche de  $\hat{\theta}_{\text{MV}}$

- On cherche  $\theta$  tel que  $\frac{\partial L(X_1, \dots, X_n; \theta)}{\partial \theta} = 0$  ou  $\frac{\partial \ln L(X_1, \dots, X_n; \theta)}{\partial \theta} = 0$
- Puis éventuellement tableau de variations pour vérifier ou alors on étudie  $\frac{\partial^2 \ln L(X_1, \dots, X_n; \hat{\theta}_{\text{MV}})}{\partial \theta^2} < 0$

## 1.5. Méthode des moments (construire un estimateur)

**Définition 1.5.1:** Estimateur des moments

$$\hat{\theta}_{\text{Mo}} = h(\hat{m}_1, \dots, \hat{m}_q) \text{ avec } \hat{m}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Utile car en général le paramètre à estimer  $\theta$  est lié **aux premiers moments** de la loi des  $X_i$ , i.e.  $\theta = h(m_1, \dots, m_q)$  avec  $m_k = E[X_i^k]$ ,  $q \geq p$

## 1.6. Estimation Bayésienne

**Définition 1.6.1:** Estimation Bayésienne

On va estimer un paramètre inconnu  $\theta \in \mathbb{R}^p$  à l'aide de la vraisemblance des  $X_1, \dots, X_n$ , et une loi à priori  $p(\theta)$ .

Pour cela on minimise une fonction de coût  $c(\theta, \hat{\theta})$  qui représente l'erreur entre  $\theta$  et  $\hat{\theta}$ .

Deux estimateurs principaux :

- MMSE : moyenne de la loi à posteriori

$$\hat{\theta}_{\text{MSE}} = E[\theta \mid X_1, \dots, X_n]$$

- MAP : estimateur du maximum à posteriori de  $\theta$  est définie par

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} p(\theta \mid X_1, \dots, X_n)$$

On appelle

- $p(\theta)$  loi à **priori** de  $\theta$
- $p(\theta \mid X_1, \dots, X_n)$  loi à **posteriori** de  $\theta$

**Théorème 1.6.1:** MMSE

L'estimateur MMSE minimise l'erreur quadratique moyenne (Mean Square Error, MSE)

On a

$$c(\theta, \hat{\theta}) = E[(\theta - \hat{\theta})^T (\theta - \hat{\theta})]$$

**Théorème 1.6.2:** MAP

L'estimateur MAP minimise la fonction de coût  $E[c(\theta, \hat{\theta})]$  en moyenne (moyenne à posteriori) avec

$$c(\theta, \hat{\theta}) = \begin{cases} 1 & \text{si } \|\theta - \hat{\theta}\| > \Delta \\ 0 & \text{si } \|\theta - \hat{\theta}\| < \Delta \end{cases}$$

Avec  $\Delta$  arbitrairement petit

### Exemple : Estimation Bayésienne

Exemple :

- Vraisemblance :  $X_i \sim \mathcal{N}(\theta, \sigma^2)$
- Loi à priori :  $\theta \sim \mathcal{N}(\mu, \nu^2)$

Solution

- Loi à posteriori :  $\theta \mid X_1, \dots, X_n \sim \mathcal{N}(m_p, \sigma_p^2)$
- Estimateurs :  $\hat{\theta}_{\text{MAP}} = \hat{\theta}_{\text{MMSE}} = m_p = \bar{X} \left( \frac{n\nu^2}{n\mu^2 + \sigma^2} \right) + \mu \left( \frac{\sigma^2}{\sigma^2 + n\nu^2} \right)$

## 2. Tests Statistiques

### Définition 2.1: Tests statistiques

- Observations :
  - $X_1, \dots, X_n$   $n$  VA i.e.d.
  - $L(X_1, \dots, X_n; \theta)$
- Hypothèses
  - Hypothèses simples :  $H_0 : \theta = \theta_0, H_1 : \theta = \theta_1$
  - Hypothèse composites  $H_0 : \theta = \theta_0, H_1 : \theta > \theta_0$

Constuire une statistique de test  $T(X_1, \dots, X_n)$  Règle de test :  $\begin{cases} \text{si } T(x_1, \dots, x_n) \in \Delta: \text{rejet } H_0 \\ \text{sinon accepter } H_0 \end{cases}$

$\Delta$  : zone critique de test = zone de rejet de  $H_0$

### Définition 2.2:

- Risque de première espèce (fausse alarme) :  $\alpha = \text{PFA} = P[\text{Rejeter } H_0 \mid H_0 \text{ vraie}]$
- Risque de seconde espèce (non détection) :  $\beta = \text{PND} = P[\text{Rejeter } H_1 \mid H_1 \text{ vraie}]$
- Puissance du test (proba de détection) :  $\pi = 1 - \beta$

### Définition 2.3: p-valeur

La proba de fausse alarme la plus petite telle qu'on rejette le test, i.e. la plus petite valeur de  $\alpha$  telle que  $H_0$  est rejetée.

$$p(x) = \inf\{\alpha \in ]0, 1[ \mid x \in \mathcal{R}_\alpha\}$$

**Théorème 2.1 :** Théorème de Neyman-Pearson

Test paramétrique à hypothèses simples :  $H_0 : \theta = \theta_0$ ,  $H_1 : \theta = \theta_1$

Rejet de  $H_0$  si :

Cas $X_i$ continues	Cas $X_i$ discètes
$\frac{L(x_1, \dots, x_n \mid H_1)}{L(x_1, \dots, x_n \mid H_0)}$ $= \frac{p(x_1, \dots, x_n \mid \theta_1)}{p(x_1, \dots, x_n \mid \theta_0)} > S_\alpha$	$\frac{L(x_1, \dots, x_n \mid H_1)}{L(x_1, \dots, x_n \mid H_0)}$ $= \frac{P[X_1 = x_1, \dots, X_n = x_n \mid \theta_1]}{P[X_1 = x_1, \dots, X_n = x_n \mid \theta_0]} > S_\alpha$

**Exemple :**  $X_i \sim \mathcal{P}(\lambda)$ 

Règle du test : si  $T = \sum X_i > S_\alpha$  alors rejet  $H_0$

$\leadsto$  zone critique du test :  $\Delta = ]S_\alpha, +\infty[$

Détermination du seuil :

$$\alpha = P[\text{rejeter } H_0 \mid H_0 \text{ vraie}] = P[T = \sum X_i > S_\alpha \mid ?]$$

où ? représente la loi de  $T$  sous  $H_0$  (on aurait  $\lambda = \lambda_0$ )

Loi de  $T$  ?

avec  $T = \sum X_i$ ,  $X_i \sim \mathcal{P}(\lambda)$  iid

On calcule la F.C. :

$$\begin{aligned}\Phi_T(u) &= E[e^{iTu}] \\ &= \prod_{i=1}^n E[e^{ju \Sigma X_i}] \\ &= e^{n\lambda(e^{ju}-1)}\end{aligned}$$

Ainsi

$$T \sim \mathcal{P}(n\lambda)$$

Donc :

- Sous  $H_0$  :  $T \sim \mathcal{P}(n\lambda_0)$
- Sous  $H_{10}$  :  $T \sim \mathcal{P}(n\lambda_1)$

Puis

$$\begin{aligned}\alpha &= P[T > S_\alpha \mid T \sim \mathcal{P}(n\lambda_0)] \\ &= 1 - P[T < S_\alpha \mid T \sim \mathcal{P}(n\lambda_0)] \\ &= 1 - \sum_{k=0}^{\text{Plan}(S_\alpha)} \left( \frac{(n\lambda_0)^k}{k!} \right) e^{-n\lambda_0}\end{aligned}$$

Et avec  $\alpha = 5\%$

$$95\%? + \begin{cases} k=0: e^{-\lambda_0 n} \\ k=1: \frac{n\lambda_0}{1} e^{-\lambda_0 n} \\ k=2: \frac{(n\lambda_0)^2}{2!} e^{-\lambda_0 n} \end{cases}$$

Généralement on utilise un calculateur

**Théorème 2.2:** Test du rapport de vraisemblance généralisé (Neyman Pearson pour hypothèses composites)

Très compliqué à la main, on le fera sûrement pas en TD (ni partiel en théorie)

Test paramétrique à hypothèses composites :  $H_0 : \theta \in \Theta_0, H_1 : \theta \in \Theta_1$

Rejet de  $H_0$  si :

$$\frac{L(x_1, \dots, x_n \mid \hat{\theta}_1^{\text{MV}})}{L(x_1, \dots, x_n \mid \hat{\theta}_0^{\text{MV}})} > S_\alpha$$

où  $\hat{\theta}_0^{\text{MV}}$  et  $\hat{\theta}_1^{\text{MV}}$  sont les estimateurs du maximum de vraisemblance de  $\theta$  sous les hypothèses  $H_0$  et  $H_1$

$$L(x_1, \dots, x_n \mid \hat{\theta}_i^{\text{MV}}) = \sup_{\theta \in \Theta_i} L(x_1, \dots, x_n \mid \theta)$$

### 3. Au partiel

- Faire un test de Neymann Pearson, construire une stat etc