

## TP1 – Estimations d'une droite de régression

Lancez le script [exercice\\_0](#) qui génère et affiche une droite ainsi que des points  $P_i$  autour de cette dernière, simulant du bruit sur les données. À partir de ces données, on va chercher à estimer les paramètres de la droite de quatre manières différentes qui sont :

- par le maximum de vraisemblance à partir de l'équation paramétrique dans l'exercice 1,
- par les moindres carrés à partir de l'équation paramétrique dans l'exercice 2,
- par le maximum de vraisemblance à partir de l'équation cartésienne normalisée dans l'exercice 3,
- par les moindres carrés à partir de l'équation cartésienne normalisée dans l'exercice 4.

### Exercice 1 : estimation de $\mathcal{D}_{YX}$ par le maximum de vraisemblance

Si  $n$  points  $P_i = (x_i, y_i)$  du plan sont au voisinage d'une droite  $\mathcal{D}$  d'équation paramétrique  $y = ax + b$ , il est légitime de modéliser les résidus  $r_{(a,b)}(P_i) = y_i - \hat{y}_i = y_i - ax_i - b$  par une loi normale centrée d'écart-type  $\sigma$  :

$$f_{(\sigma,a,b)}(P_i) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{r_{(a,b)}(P_i)^2}{2\sigma^2}\right\} \quad (1)$$

La droite de régression de  $Y$  en  $X$  d'un tel nuage de points, notée  $\mathcal{D}_{YX}$ , est la droite d'équation paramétrique  $y = a^*x + b^*$ , où  $a^*$  et  $b^*$  sont les valeurs des paramètres  $a$  et  $b$  qui maximisent la log-vraisemblance :

$$(\sigma^*, a^*, b^*) = \arg \max_{(\sigma,a,b) \in \mathbb{R}^+ \times \mathbb{R}^2} \left\{ \ln \prod_{i=1}^n f_{(\sigma,a,b)}(P_i) \right\} = \arg \min_{(\sigma,a,b) \in \mathbb{R}^+ \times \mathbb{R}^2} \sum_{i=1}^n \left\{ \ln \sigma + \frac{r_{(a,b)}(P_i)^2}{2\sigma^2} \right\} \quad (2)$$

Si l'on suppose l'écart-type  $\sigma$  fixé, alors le problème revient à minimiser la Somme des Carrés Résiduelle (SCR) :

$$(a^*, b^*) = \arg \min_{(a,b) \in \mathbb{R}^2} \sum_{i=1}^n r_{(a,b)}(P_i)^2 = \arg \min_{(a,b) \in \mathbb{R}^2} \sum_{i=1}^n (y_i - ax_i - b)^2 \quad (3)$$

La résolution de (3) par tirages aléatoires n'est pas aussi simple qu'il y paraît car : d'une part les inconnues  $a$  et  $b$  ne sont pas bornées, et d'autre part  $a$  ne suit pas une loi uniforme. Néanmoins, il est facile de montrer que  $\mathcal{D}_{YX}$  contient le centre de gravité  $G$  des points  $P_i$ . On peut donc calculer les coordonnées  $(x_G, y_G)$  de  $G$ , puis centrer les données. L'équation de  $\mathcal{D}_{YX}$  devenant  $y' = a^*x'$  après changement d'origine, et le problème se simplifie encore :

$$a^* = \arg \min_{a \in \mathbb{R}} \sum_{i=1}^n (y'_i - ax'_i)^2 = \tan \left\{ \arg \min_{\psi \in ]-\frac{\pi}{2}, \frac{\pi}{2}[} \sum_{i=1}^n (y'_i - \tan \psi x'_i)^2 \right\} \quad (4)$$

Dans (4), la deuxième égalité vient du fait que le paramètre  $a$  d'une droite est égal à la tangente de son angle polaire  $\psi$ . La résolution de (4) peut être effectuée par tirages aléatoires de  $\psi$  selon une loi uniforme sur l'intervalle  $]-\frac{\pi}{2}, \frac{\pi}{2}[$ .

Dans un premier temps, complétez la fonction [centrage\\_des\\_donnees](#) qui retourne les coordonnées  $x_G$  et  $y_G$  du centre de gravité ainsi que les vecteurs centrés des données ( $x'_i = x_i - x_G$  et  $y'_i = y_i - y_G$ ). Afin d'effectuer les tirages aléatoires de  $\psi$  selon une loi uniforme, complétez également la fonction [tirages\\_aleatoires\\_uniformes](#) en vous basant sur celle du TP de Probabilités. Complétez ensuite la fonction [estim\\_param\\_Dyx\\_MV](#), appelée par le script [exercice\\_1](#), permettant de résoudre le problème (4) correspondant au maximum de vraisemblance pour l'équation paramétrique. Afin de vérifier que la distribution des résidus  $r_{(a^*,b^*)}(P_i) = y'_i - \tan \psi^* x'_i$  suit bien une loi normale, la fonction doit également retourner un vecteur contenant ces derniers. Lancez ensuite le script [exercice\\_1bis](#) affiche en plus l'histogramme de la distribution des résidus ainsi que la probabilité associée, qui, dans le cas d'une bonne estimation, doivent suivre le modèle théorique d'une loi normale.

## Exercice 2 : estimation de $\mathcal{D}_{YX}$ par les moindres carrés

Le critère à minimiser dans (2) peut se réécrire sous la forme  $\mathcal{F}(\sigma, a, b) = n \ln \sigma + \frac{1}{2\sigma^2} \sum_{i=1}^n r_{(a,b)}(P_i)^2$ . Le problème (2) peut donc également être considéré comme un problème d'optimisation différentiable. En notant  $\mathcal{G}(a, b) = \sum_{i=1}^n r_{(a,b)}(P_i)^2$  qui est là encore la Somme des Carrés Résiduelle (SCR), on obtient :

$$\nabla \mathcal{F}(\sigma, a, b) = 0 \iff \begin{cases} \nabla_{\sigma} \mathcal{F}(\sigma, a, b) = 0 \\ \nabla_{a,b} \mathcal{F}(\sigma, a, b) = 0 \end{cases} \iff \begin{cases} \sigma^2 = \frac{1}{n} \sum_{i=1}^n r_{(a,b)}(P_i)^2 \\ \nabla \mathcal{G}(a, b) = 0 \end{cases} \quad (5)$$

La première de ces équations était prévisible, puisque c'est la définition même de la variance. Quant à la deuxième équation, elle correspond à l'optimalité du critère à minimiser dans (3). Or, ce critère s'écrit aussi :

$$\mathcal{G}(a, b) = \|AX - B\|^2, \text{ où } A = \begin{bmatrix} x_1 & \cdots & x_n \\ 1 & \cdots & 1 \end{bmatrix}^T, X = \begin{bmatrix} a \\ b \end{bmatrix} \text{ et } B = [y_1 \quad \cdots \quad y_n]^T \quad (6)$$

Minimiser  $\mathcal{G}(a, b)$  revient donc à chercher une solution approchée du système linéaire  $AX = B$ , au sens des moindres carrés (voir cours d'Analyse de Données). Le problème se résout en écrivant les *équations normales*  $A^T AX = A^T B$ , dont la solution s'écrit  $X^* = (A^T A)^{-1} A^T B = A^+ B$ , où  $A^+ = (A^T A)^{-1} A^T$  est la *matrice pseudo-inverse* de  $A$ . Une condition suffisante à la validité d'un modèle linéaire est d'avoir une valeur pas trop proche de 0 pour le coefficient de détermination  $R^2$ . Ce dernier est défini de la façon suivante avec la Somme des Carrés Totale (SCT) et la Somme des Carrés Résiduelle (SCR) :

$$R^2 = 1 - \frac{\text{SCR}}{\text{SCT}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - y_G)^2} = 1 - \frac{\sum_{i=1}^n (y_i - a^* x_i - b^*)^2}{\sum_{i=1}^n (y_i - y_G)^2} \quad (7)$$

Complétez la fonction `estim_param_Dyx_MC1`, appelée par le script `exercice_2`, permettant de comparer cette méthode d'estimation de  $\mathcal{D}_{YX}$  avec celle de l'exercice 1. En lançant plusieurs fois le script, observez ce qui se passe lorsque la droite réelle est quasi-horizontale ou quasi-verticale.

D'autre part, en effectuant les calculs à la main pour trouver  $X^*$  (et que l'on vous conseille de faire chez vous), on obtient directement les valeurs suivantes pour les paramètres :

$$r = \frac{\text{cov}([x_1 \cdots x_n]^T, [y_1 \cdots y_n]^T)}{\sqrt{\text{var}([x_1 \cdots x_n]^T) \text{var}([y_1 \cdots y_n]^T)}} \implies a = r \sqrt{\frac{\text{var}([y_1 \cdots y_n]^T)}{\text{var}([x_1 \cdots x_n]^T)}} \implies b = y_G - a x_G \quad (8)$$

où le coefficient de détermination  $R^2$  est en fait égal au carré de la corrélation entre les données  $x_i$  et  $y_i$ . Complétez la fonction `estim_param_Dyx_MC2` qui retourne les paramètres de (8), appelée par le script `exercice_2bis`, et vérifiez que vous obtenez bien les mêmes résultats qu'avec l'estimation précédente.

Afin de savoir si le modèle linéaire avec les coefficients obtenus sont bons, il est nécessaire d'effectuer des tests d'hypothèse. Dans cette optique, la fonction `fitlm` permet de créer un modèle linéaire à partir des données  $x_i$  et  $y_i$ . Elle permet aussi de donner une indication sur la qualité du modèle avec le test de Fisher, noté **F-statistic**, (hypothèse  $H_0$  : tous les coefficients hors ordonnée à l'origine sont nuls) et sur la qualité des coefficients avec le test de Student, noté **tStat**, (hypothèse  $H_0$  : le coefficient est nul). Lancez le script `exercice_2ter` pour visualiser la droite estimée ainsi que l'intervalle de confiance à 95% autour de cette dernière. Le script affiche aussi le modèle linéaire dans la fenêtre de commande comprenant les résultats que vous devez obtenir, avec les valeurs des différents tests et les p-valeurs associées. À partir de ces dernières, que pouvez-vous conclure quant à la qualité du modèle estimé en prenant un seuil de décision  $S_\alpha$  de 1% (i.e. la p-valeur doit être inférieure à 0,01 pour rejeter l'hypothèse  $H_0$ ) ?

## Exercice 3 : estimation de $\mathcal{D}_\perp$ par le maximum de vraisemblance

Une droite  $\mathcal{D}$  du plan peut également être définie par son *équation cartésienne normalisée*  $x \cos \theta + y \sin \theta = \rho$ , où  $(\rho, \theta)$  sont les coordonnées polaires de la projection orthogonale sur  $\mathcal{D}$  de l'origine  $O$  du repère. Si l'on note  $(x_Q, y_Q)$  les coordonnées cartésiennes de ce point, appelé  $Q$ , alors la distance à l'origine de  $Q$  vaut  $\rho = \sqrt{x_Q^2 + y_Q^2} \in \mathbb{R}^+$  et l'angle polaire  $\theta = \arctan\left(\frac{y_Q}{x_Q}\right) \in \left]-\frac{\pi}{2}, \frac{\pi}{2}\right]$ .

Dans le cas où la droite  $\mathcal{D}$  passe par l'origine  $O$ , l'angle polaire  $\theta$  de  $Q = O$  n'est pas défini. L'équation cartésienne normalisée de  $\mathcal{D}$  s'écrit alors  $x \cos \theta + y \sin \theta = 0$ , où  $\theta$  est l'angle polaire d'un des vecteurs orthogonaux à  $\mathcal{D}$ , défini à  $\pi$  près.

Il semble légitime de modéliser les résidus  $r_{(\theta,\rho)}(P_i) = x_i \cos \theta + y_i \sin \theta - \rho$  par une loi normale centrée :

$$f_{(\sigma,\theta,\rho)}(P_i) = \frac{1}{\sigma \sqrt{2\pi}} \exp \left\{ -\frac{r_{(\theta,\rho)}(P_i)^2}{2\sigma^2} \right\} \quad (9)$$

La droite de régression en distance orthogonale du nuage de points, notée  $\mathcal{D}_\perp$ , est la droite ayant pour équation  $x \cos \theta^* + y \sin \theta^* = \rho^*$ , où  $\theta^*$  et  $\rho^*$  sont les valeurs des paramètres  $\theta$  et  $\rho$  qui maximisent la log-vraisemblance :

$$(\sigma^*, \theta^*, \rho^*) = \arg \max_{(\sigma,\theta,\rho) \in \mathbb{R}^+ \times \left[-\frac{\pi}{2}, \frac{\pi}{2}\right] \times \mathbb{R}^+} \left\{ \ln \prod_{i=1}^n f_{(\sigma,\theta,\rho)}(P_i) \right\} = \arg \min_{(\sigma,\theta,\rho) \in \mathbb{R}^+ \times \left[-\frac{\pi}{2}, \frac{\pi}{2}\right] \times \mathbb{R}^+} \sum_{i=1}^n \left\{ \ln \sigma + \frac{r_{(\theta,\rho)}(P_i)^2}{2\sigma^2} \right\} \quad (10)$$

En supposant  $\sigma$  fixé, et sachant que la droite de régression  $\mathcal{D}_\perp$  contient elle aussi le centre de gravité  $G$ , la résolution du problème (7) est en tout point analogue à celle du problème (2). Par analogie avec (4) :

$$\theta^* = \arg \min_{\theta \in \left[-\frac{\pi}{2}, \frac{\pi}{2}\right]} \sum_{i=1}^n (x'_i \cos \theta + y'_i \sin \theta)^2 \quad (11)$$

Complétez la fonction `estim_param_Dorth_MV`, appelée par le script `exercice_3`, permettant de résoudre le problème (8) correspondant au maximum de vraisemblance pour l'équation cartésienne normalisée.

## Exercice 4 : estimation de $\mathcal{D}_\perp$ par les moindres carrés

Le critère  $\mathcal{I}(\theta) = \sum_{i=1}^n (x'_i \cos \theta + y'_i \sin \theta)^2$  à minimiser dans (11) s'appelle l'*inertie*. Il s'écrit également :

$$\mathcal{I}(\theta) = \|CY\|^2, \text{ où } C = \begin{bmatrix} x'_1 & \cdots & x'_n \\ y'_1 & \cdots & y'_n \end{bmatrix}^\top \text{ et } Y = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix} \quad (12)$$

Or, la solution approchée du système linéaire  $CY = O$ , au sens des moindres carrés ordinaires, vaut  $C^+O = O$ . Pour éviter cette solution, on impose la contrainte  $\|Y\| = 1$ . Ce nouveau problème se résout en introduisant le *lagrangien*  $\mathcal{L}(Y, \lambda) = \|CY\|^2 + \lambda(1 - \|Y\|^2)$ , où  $\lambda$  constitue un *multiplicateur de Lagrange*. La condition d'optimalité de  $\mathcal{L}$  s'écrit :

$$\nabla \mathcal{L}(Y, \lambda) = 0 \iff \begin{cases} \nabla_Y \mathcal{L}(Y, \lambda) = 0 \\ \nabla_\lambda \mathcal{L}(Y, \lambda) = 0 \end{cases} \iff \begin{cases} C^\top CY = \lambda Y \\ \|Y\| = 1 \end{cases} \quad (13)$$

Sachant que  $C^\top C$  est symétrique réelle, cette matrice admet une base orthonormée de vecteurs propres. De plus, comme  $C^\top C$  est *semi-définie positive*, ses valeurs propres sont positives ou nulles. Le minimiseur de  $\mathcal{I}(\theta)$  dont la norme est égale à 1, noté  $Y^*$ , est donc le vecteur propre associé à la plus petite valeur propre de  $C^\top C$ . Il s'agit du vecteur perpendiculaire à celui correspondant à l'axe qui est le long des points (par analogie au vecteur normal définissant un plan dans l'espace). En effet, pour un vecteur propre  $Y_p$  de norme 1, associé à la valeur propre  $\lambda_p$ , on a :

$$\|CY_p\|^2 = Y_p^\top C^\top CY_p = \lambda_p Y_p^\top Y_p = \lambda_p. \quad (14)$$

Écrivez la fonction `estim_param_Dorth_MC`, appelée par le script `exercice_4`, permettant de comparer cette méthode d'estimation de  $\mathcal{D}_\perp$  à celle de l'exercice 3. La fonction `eig` permet de calculer les valeurs propres et vecteurs propres de la matrice  $C^\top C$ . La valeur de l'angle  $\theta$  s'obtient quant à elle avec la fonction `atan`. Observez l'évolution des résultats en fonction de  $n$  et de  $n_{\text{tests}}$ , et aussi dans le cas où la droite réelle est quasi-v verticale.